

Region-Disentangled Diffusion과 주파수 정보 융합을 통한 ECG 다중 리드 생성 및 질환 예측 정확도 향상

(Enhancing Multi-Lead ECG Generation and Disease Prediction Accuracy via Region-Disentangled Diffusion and Frequency Information Fusion)

요약 본 연구는 단일 리드 ECG로부터 다중 리드 ECG를 생성하고, 이를 통해 심혈관 질환 분류 성능을 향상하기 위한 새로운 생성 모델을 제안한다. 기존 확산 모델인 RDDM 구조를 기반으로, 주파수 정보를 효과적으로 활용하기 위해 생성 신호와 실제 신호의 주파수 스펙트럼 차이를 반영한 FFT 기반 손실 함수를 추가하였다. 제안한 모델은 PTB-XL 데이터셋을 활용한 실험에서 기존 RDDM 대비 더 우수한 ECG 생성 성능을 보였으며, 생성된 다중 리드 신호를 활용한 심혈관 질환 분류에서도 F1-score와 ROC-AUC가 개선되는 결과를 확인하였다. 본 연구는 생성 신호의 임상적 활용 가능성을 높이는 방향으로 확산 모델을 확장한 데 의의가 있다.

키워드: 심전도(ECG) 생성, 확산 모델, 영역 분리 확산 모델(RDDM), 고속 푸리에 변환(FFT)

Abstract This study presents an enhanced ECG synthesis framework that reconstructs 12-lead signals from a single-lead input while boosting diagnostic accuracy. Extending the Region-Disentangled Diffusion Model (RDDM), the authors add two frequency-aware innovations: an FFT-based loss that reduces spectral gaps and a time-frequency fusion conditioning network that encodes both temporal shapes and frequency content. On the PTB-XL dataset, the method outperforms baseline RDDM in signal fidelity and raises F1-score and ROC-AUC for cardiovascular disease classification, underscoring the clinical promise of frequency-integrated diffusion models.

Key words : Electrocardiogram(ECG) Generation, Diffusion Models, Region-Disentangled Diffusion Model(RDDM), Fast Fourier Transform(FFT)

1. 서론

심혈관 질환은 전 세계적으로 주요 사망 원인 중 하나이며, 국내에서도 환자 수의 증가와 함께 사회·경제적 부담이 지속적으로 확대되고 있다. 이에 따라 조기 진단과 지속적인 모니터링의 중요성이 강조되고 있다. 최근 스마트 워치 등 웨어러블 디바이스(Wearable Device)의 발전으로 단일 리드 ECG(Electrocardiogram, 심전도) 신호를 실시간으로 측정할 수 있게 되면서 개인 건강 관리의 접근성이 크게 향상되었다.

그러나 상용화된 대부분의 웨어러블 디바이스는 단일 리드(주로 Lead I)만 제공하여, 병원에서 사용되는 12-리드 ECG와 비교했을 때 정밀한 분석에 한계가 존재한다. 12-리드 ECG는 심장을 다양한 각도에서 관찰할 수 있도록 설계되어 있어 심근경색, 부정맥 등 주요 심혈관 질환의 위치와 유형을 파악하는 데 필수적인 정보를 제공한다. 이러한 한계를 극복하기 위해 단일 리드 ECG로부터 다중 리드를 복원하거나 생성하는 연구가 활발히 진행되고 있다[1]. 기존에 VAE, GAN 기반 모델도 시도되었으나, ECG 신호 특성을 충분히 반영하지 못해 임상 적용에는 제약이 있었다.

본 연구의 목적은 웨어러블 ECG의 단일 리드 구조가 갖는 진단적 한계를 극복하는 데 있다. 이를 위해 기존 RDDM(Region-Disentangled Diffusion Model)[2]에 주파수 영역 손실 함수를 적용하여, 단일 리드 ECG로부터 다중 리드 ECG를 생성하는 과정에서 고주파 영역 노이즈를 효과적으로 제거하고, 나아가 ECG 생성 성능 및 심혈관 질환 분류 성능을 개선하고자 한다.

2. 배경 및 관련 연구

2.1 ECG 생성 모델

단일 리드 ECG의 구조적 한계를 극복하고 임상적 진단 가치를 높이기 위한 방안으로, 제한된 리드 정보를 기반으로 전체 12-리드 ECG를 재구성하는 생성 모델 기반 연구가 활발히 진행되고 있다.

초기에는 VAE(Variational Autoencoder) 및 GANs(Generative Adversarial Networks) 기반의 접근이 주를 이루었다. CycleGAN을 활용하여 리드 간 ECG 변환이 수행되었고[3], ECG-Dual-GAN을 통해 조건부 ECG 생성이 제안되었다[4]. 그러나 GAN 기반 모델은 학습의 불안정성, 모드 붕괴(mode collapse) 등의 문제가 자주 발생하며, 의료 도메인에서 요구되는 안정적이고 신뢰성 높은 생성에는 한계가 존재한다.

최근에는 DDPM(Denoising Diffusion Probabilistic Models) 기반의 확산 모델이 높은 품질과 안정성을 바탕으로 주목받고 있다. 특히 임상 진술(clinical statements)을 조건으로 ECG를 생성하는 텍스트-신호 기반 모델이 제안되었으며[5], DiffECG는 클래스 조건(class-conditional)의 반영을 통해 DDPM이 다양한 ECG 유형을 정밀하게 생성할 수 있음을 보였다[6].

이처럼 확산 모델은 의료 신호 생성의 새로운 대안으로 부상하고 있으며, 최근에는 ECG뿐만 아니라 EEG, PPG 등 다양한 생체신호 생성에도 확장되고 있다.

2.2 DDPM 및 RDDM

DDPM은 입력 데이터를 점진적으로 가우시안 노이즈로 오염시키는 정방향 과정(forward process)과, 이를 점차적으로 제거하며 원래 데이터를 복원하는 역방향 과정(reverse process)을 기반으로 하는 생성 모델이다[7].

이러한 구조는 기존 GAN이나 VAE에 비해 훈련 안정 성과 생성 품질 측면에서 우수하며, 특히 복잡한 구조적 특징을 갖는 신호나 이미지에 대해 높은 재현 능력을 보인다. 또한, 조건 정보를 활용한 조건부 생성(conditioned generation)이 가능해 다양한 도메인에 유연하게 적용할 수 있다는 장점이 있다. 이후 다양한 확장 연구들이 이루어지며, DDPM은 음성 합성, 영상 생성, 생체 신호 생성 등에서 최신 성능을 달성하는 모델로 발전하고 있다[8].

본 연구의 기반이 된 모델인 RDDM은 기존 DDPM의 무차별적 노이즈 추가 방식을 개선하여, 의학적으로 중요한 영역(Region of Interest, ROI)에만 선택적으로 노이즈를 주입하는 방식을 도입한 모델이다[2]. ECG 신호의 경우, QRS complex 영역은 고주파 정보를 포함하며 심장 리듬 분석에 핵심적인 구간이다. RDDM은 이러한 중요한 영역에 집중적으로 노이즈를 주입한 후, ROI와 비-ROI 영역을 분리하여 복원하는 disentangled reverse process를 사용함으로써 전체적인 파형과 세부 형상 정보를 효과적으로 보존할 수 있다. 해당 모델은 PPG(Photoplethysmogram, 광혈류 측정 신호)로부터 ECG를 생성하는 실험에서 기존 실험 성능 대비 19% 개선을 달성했으며, 고해상도 ECG 생성에 적합한 확산 모델 구조임을 입증했다.

2.3 FFT

FFT(Fast Fourier Transform)는 시간 영역에서 수집된 신호를 주파수 영역으로 변환하는 효율적인 알고리즘으로, 신호가 어떤 주파수 성분으로 구성되어 있는지를 정량적으로 분석할 수 있게 해준다. 이는 Fourier Transform의 계산 복잡도를 크게 줄여, 디지털 신호 처리에서 널리 사용된다[9].

ECG와 같은 생체 신호는 본질적으로 시간에 따라 변화하는 연속적인 파형이지만, 이 신호에는 다양한 주파수 성분이 내포되어 있다. 이러한 주파수 성분은 심장 전기생리학적 활동의 다른 양상을 반영하며, 심장 질환의 진단에 있어 중요한 정보가 된다.

따라서 시간 영역에서 파형의 특정 특징이 잘 드러나지 않더라도, 주파수 영역에서는 해당 특징이 뚜렷하게 나타날 수 있다. 주파수 도메인 분석은 이러한 주파수 구성 요소를 분리하고 정량화하여 신호의 구조적 특성을 더 명확히 파악할 수 있게 해주며, 잡음 제거[10], 이상 검출[11], 질환의 병리학적 특성 파악 등 다양한 목적에 활용된다.

본 연구에서는 이러한 FFT의 장점을 기반으로, 기존의 RDDM 모델로는 완벽히 제거하지 못한 고주파 영역 노이즈를 효과적으로 제거하고자 하였다.

3. 제안 방법

3.1 기존 방법의 문제점

기존의 RDDM 모델은 QRS complex 영역에 상대적으로 더 많은 노이즈를 주입·제거함으로써, ECG 신호의 핵심적인 부분에 집중하여 원




그림 1 원 신호와 RDDM으로 복원한 신호의 시각화(좌측) 및 스펙트로그램(우측)

Fig 1. Spectrogram and waveform comparison of the reference ECG and the RDDM-reconstructed ECG (left: waveform visualization; right: spectrogram)

신호와 유사한 형태로 복원하는 데 강점이 있다. 그러나, 해당 모델만으로는 QRS complex에 잔존하는 노이즈를 올바르게 제거하지 못해, 복원된 신호의 품질이 저하되는 문제가 있었다.

그림 1은 동일한 구간의 ECG를 두 관점에서 비교해, 시계열에서 관찰되는 노이즈가 주파수 도메인으로 변환했을 때도 일관된 차이로 나타남을 보여주는 도식이다. 좌측은 시계열 파형 시각화, 우측은 해당 신호를 푸리에 변환으로 변환한 스펙트로그램이다.

그림 1의 좌측 시각화 그래프에 따르면, 실제 신호(초록)와 생성된 신호(빨강)의 QRS complex 부분에 표시된 노란색 박스를 통해 생성된 신호의 노이즈를 확인할 수 있다.

그림 1의 우측 스펙트로그램에서, 컬러 스케일은 진할수록(질은 적색) 에너지가 낮고, 밝을수록(노랑) 에너지가 높은 구간을 의미한다. 즉, 같은 시간-주파수 좌표에서 색이 더 밝으면 해당 성분의 크기가 더 크다는 뜻이다.

생성 신호의 에너지 분포가 실제 신호 대비 불규칙하고 일관성이 떨어지는 양상을 확인할 수 있다. 즉, 시각화 그래프에서 관찰된 노이즈가 주파수 도메인에서도 뚜렷하게 드러나며, 이는 단순한 시간 도메인 복원만으로는 충분하지 않음을 시사한다.

3.2 FFT 기반 손실 함수 제안

기존 모델의 문제점을 해결하기 위해, 본 연구에서는 학습 시 FFT loss를 추가적으로 도입하는 방법을 제안한다. FFT loss는 예측 신호와 타깃 신호에 대해 FFT를 수행하여 크기 스펙트럼을 계산하고, 이들의 L1 오차(mean absolute error)를 손실로 사용한다. 주파수 영역에서의 오차를 기반으로 손실을 계산함으로써, 생성 신호에 고주파 노이즈가 잔존할 경우 원 신호와의 차이를 명확하게 반영할 수 있다. 따라서 모델은 FFT loss를 줄이기 위해 고주파 노이즈를 제거하도록 학습된다.

제안하는 방법을 따른 훈련 목표 함수는 확산 모델의 표준 노이즈 예측 loss와 주파수 정보 일치를 위한 FFT loss 두 가지로 구성되게 된다. FFT loss는 예측 신호와 실제 신호에 대해 FFT를 취해 크기 스펙트럼을 구하고, 두 크기 차이의 평균 절댓값으로 정의된다(1).

$$L_{FFT} = \frac{1}{M} \sum \left| \text{mag} \left(\text{FFT}(X_{pred}) \right) - \text{mag} \left(\text{FFT}(X_{target}) \right) \right| \quad (1)$$

최종 훈련 목표는 표준 노이즈 예측 손실 DDPM loss, QRS 중심 영역 유도 손실 Region loss, 그리고 제한하는 주파수 도메인 손실 FFT loss의 가중 합으로 구성된다(2).

$$L_{total} = \alpha_1 \cdot L_{DDPM} + \alpha_2 \cdot L_{region} + \alpha_{FFT} \cdot L_{FFT} \quad (2)$$

4. 실험

4.1 데이터

본 연구에서는 PhysioNet의 12 리드로 구성된 PTB-XL 데이터를 활용하였다. 해당 데이터는 10초간 500Hz로 측정된 데이터이며, NORM, HYP, MI, CD, STTC으로 총 5개의 멀티-레이블을 가진다.

본 연구에서는 이 데이터를 멀티 클래스 작업으로 활용하기 위해 여러 레이블이 혼재된 샘플은 제외하였다. 학습, 테스트 데이터는 7:3 비율로 분할하였다. 총 샘플 수는 16,244개이며, 클래스 별 샘플 수는 NORM 9,069개, MI 2,532개, STTC 2,400개, CD 1,708개, HYP 535개이다.

4.2 실험 구성

4.2.1 생성 모델 구성

본 연구에서는 PTB-XL 데이터를 128Hz로 다운 샘플링한 후, 5초 간격으로 데이터를 분할하여 생성의 학습 및 추론을 진행하였다. 생성은 베이스라인 모델인 RDDM과, 제안하는 방법이 적용된 모델 두 가지를 사용하였다.

그러나 RDDM은 PPG로부터 ECG 신호를 생성하는 것을 목표로 설계된 모델이므로, 본 연구에서는 우선 RDDM의 구조를 ECG 신호를 입력받아 다른 리드의 ECG 신호를 생성하도록 모델 구조를 수정하였다. 이때 입력 리드 제외 11종의 리드를 하나의 모델로 생성하는 것이 아닌, 각 리드를 생성하는 개별 모델을 구축하는 방식으로 접근하였다. 내부 구조로는 1차원 U-Net 기반의 확산 네트워크를 사용하고, 입력 ECG를 조건으로 활용하는 cross-attention 구조를 채택하였다.

표 1 RDDM과의 생성 성능 비교(RMSE)
Table 1 Generation performance comparison with RDDM(RMSE)

RMSE	Lead II	Lead aVR	Lead aVL	Lead aVF	Lead V5	Lead V6	Average
RDDM	0.555	0.489	0.623	0.547	0.695	0.749	0.610
FFT loss(Ours)	0.550	0.256	0.507	0.774	0.652	0.501	0.540

표 2 RDDM과의 생성 성능 비교(FD)
Table 2 Generation performance comparison with RDDM(Fréchet Distance)

FD	Lead II	Lead aVR	Lead aVL	Lead aVF	Lead V5	Lead V6	Average
RDDM	199.298	110.755	113.218	94.874	204.615	260.822	163.930
FFT loss(Ours)	197.223	13.301	48.872	80.017	114.604	64.586	86.434

배치 사이즈는 32, 에포크는 120, 확산 모델의 denoising step은 10으로 하였다. 제안하는 방법의 경우 손실 함수의 가중치는 region loss, ddpm loss, FFT loss에 대해 각각 100, 1, 0.1로 설정하였다.

4.2.2 분류 모델 구성

분류 실험에서는 기존의 lead 1 신호와 해당 신호를 기반으로 생성된 신호 두 개를 입력으로 사용하였다. 하나의 샘플은 10초 길이의 데이터를 기준으로 구성하였으며, 생성 신호는 5초 단위로 생성된 데이터를 앞뒤로 연결하여 10초로 확장하였다.

시간적 제약으로 인해 11개의 리드 전체를 대상으로 실험하지 않고, RDDM의 생성 성능이 우수했던 상위 6개 리드(II, aVR, aVL, aVF, V5, V6)에 대해서만 분류 실험을 진행하였다. 분류 모델은 2D CNN 기반 구조로 설계하였으며, 전체 데이터를 학습, 검증, 테스트 세트로 6:2:2 비율로 분할하였다. 실험은 배치 크기 16으로 진행하였고, early stopping을 적용하여 최적의 에포크에서 학습을 종료하였다.

5. 실험 결과

5.1 생성 성능 평가

표 1과 표 2는 각각 RMSE(Root Mean Square Error)와 FD(Fréchet Distance)를 사용하여, Baseline인 'RDDM'과 제안하는 'FFT loss' 기반 방법의 생성 성능을 비교한 결과이다. 각 리드(lead) 별로 가장 우수한 성능은 굵게 표시하였다.

RMSE는 실제 신호와 생성된 신호 간의 평균 제곱 오차의 제곱근으로, 두 신호 간의 차이를 수치적으로 직관적으로 보여주는 지표이다. 반면, FD는 두 시계열의 전체적인 분포와 형태를 비교하여 유사도를 측정하는 지표로, 단순 오차보다는 패턴의 일치 정도를 평가할 수 있다.

RMSE 기준으로는 Lead aVF를 제외하고 대부분의 리드에서 제안한 방법이 RDDM보다 높은 성능을 보였다. FD 기준으로는 제안한 FFT loss 기반 방법이 모든 리드에서 RDDM보다 더 낮은 거리 값을 기록하였다. 특히 aVF 리드의 경우, RMSE 기준으로는 RDDM에서 더 좋은

성능을 보이지만, FD로 평가하면 제안한 방법이 더 우세하다. 이는 제안한 방법으로 생성된 신호가 개별 시점의 오차는 일부 남더라도, 전체적인 파형의 형태와 패턴 측면에서는 원 신호에 더 가깝다는 것을 의미한다.

그림 2는 원 신호와 비교하여 RDDM 및 제안한 방법으로 생성된 신호를 시각화한 결과이다. RDDM이 생성한 신호는 노란색 박스로 표시한 QRS complex 구간에 노이즈가 남아 있으며, 전반적으로 신호 간 간격이 벌어지는 경향을 보인다. 반면, 제안한 방법으로 생성된 신호는 노이즈가 효과적으로 제거되어 원 신호와 유사한 형태를 유지하고 있음을 확인할 수 있다.

5.2 분류 성능 평가

표 3은 생성된 각 리드 II, aVR, aVL, aVF, V5, V6 신호를 Lead I 신호와 결합했을 때의 분류 성능을 비교한 것이다. 이때 baseline은 RDDM뿐 아니라, 단일 신호만 사용하였을 경우와도 비교한다. 성능 지표로는 단순 정확도를 나타내는 Accuracy와, 클래스 간 샘플 개수 불균형을 반영하기 위해 F1 score 및 ROC-AUC를 추가하여 나타냈다.




그림 2 RDDM 및 제안 방법으로 생성된 신호 비교
Fig. 2 Qualitative comparison of ECGs generated by RDDM and by the proposed method

표 3 단일 신호, RDDM 생성 신호와의 분류 성능 비교

Table 3 Classification performance comparison between the single-lead baseline and the RDDM-generated signals

	Lead II			Lead aVR			Lead aVL			Lead aVF			Lead V5			Lead V6		
	Acc	F1	AUC	Acc	F1	AUC	Acc	F1	AUC	Acc	F1	AUC	Acc	F1	AUC	Acc	F1	AUC
Lead I	0.541	0.313	0.756	0.541	0.313	0.756	0.541	0.313	0.756	0.541	0.313	0.756	0.541	0.313	0.756	0.541	0.313	0.756
RDDM	0.531	0.352	0.740	0.554	0.356	0.755	0.545	0.360	0.749	0.541	0.350	0.758	0.555	0.366	0.756	0.547	0.362	0.756
FFT loss(Ours)	0.561	0.401	0.756	0.555	0.383	0.769	0.571	0.418	0.765	0.551	0.377	0.757	0.602	0.375	0.761	0.547	0.374	0.759

제안한 방법으로 생성한 신호를 분류에 적용한 결과, 대부분의 리드와 평가 지표에서 최고 성능을 달성했다. 특히 리드 II, aVL, aVR, V5 신호를 결합했을 경우, RDDM은 ROC-AUC에서 단일 리드를 사용한 것보다 성능이 떨어졌으나, 제안된 방법으로 생성한 경우 성능 향상을 보였다. 이는 제안된 방법으로 생성된 리드가 보다 정확한 심장 질환 분류에 있어 도움이 될 수 있음을 시사한다.




그림 3 생성 리드 추가에 따른 분류 F1 지표

Fig. 3 Classification F1 score with additional generated leads




그림 4 생성 리드 추가에 따른 분류 AUC 지표

Fig. 4 Classification AUC with additional generated leads

5.3 생성 리드 추가에 따른 분류 성능 변화

그림 3, 4는 생성된 리드의 개수에 따라 Lead I 신호와 결합했을 때의 분류 성능을 비교한 결과를 나타낸 것이다. 빨간 점선은 Lead I 단일 신호만을 사용한 분류 성능 baseline을 나타낸다. 분류 모델은 5.2

절에서 사용한 2D CNN을 활용하였으며, 성능 지표는 F1 score와 ROC-AUC를 사용하였다.

실험 결과, 제안한 FFT-loss 기반의 생성 리드가 전반적으로 RDDM보다 우수한 성능을 보였다. 대부분의 리드 조합과 평가 지표에서 FFT-loss는 RDDM 대비 성능 향상을 달성하였으며, 이는 제안된 손실 함수가 보다 안정적으로 의미 있는 ECG 신호를 생성하고 있음을 뒷받침한다.

반면, Lead I에 두 개 이상의 리드(aVR, aVL, aVF, V5, V6 등)를 동시에 추가하는 경우, RDDM뿐 아니라 FFT-loss 기반 생성 신호에서도 공통적으로 성능이 단일 Lead I baseline에 비해 저하되는 경향을 보였다.

예컨대 Lead I에 aVR과 aVL을 함께 조합한 경우 ROC-AUC는 오히려 감소하였으며, 리드를 다섯 개까지 확장했을 때도 동일한 현상이 반복되었다. 이는 생성된 추가 리드가 반드시 유용한 정보를 더해주는 것이 아니라, 오히려 잡음이나 중복된 정보를 포함할 수 있음을 시사한다.

6. 결론 및 제언

본 연구는 단일 리드로 주어지는 심전도 데이터의 임상적 한계를 극복하기 위해 생성 모델의 가능성을 실험적으로 검증하였다. 특히 주파수 영역의 정보를 활용하여 노이즈 억제 성능을 강화하는 방법을 제안하였으며, 이를 통해 웨어러블 ECG 데이터의 활용 가능성을 확장하였다.

실험 결과, FFT 기반 손실 함수를 추가한 제안 방법은 생성 성능 측면에서 의미 있는 개선을 보였다. 생성된 신호는 시각화 평가에서도 고주파 성분의 노이즈가 효과적으로 제거되어 목표 신호와 가까운 결과를 만들어내었으며, 이는 FD 지표를 통해서도 확인할 수 있었다.

분류 성능 측면에서도, 생성된 리드를 단일 리드와 결합하여 활용했을 때 평가 지표가 다수의 리드에서 향상되었다. 특히, aVR, aVL 리드와 결합했을 경우 분류 정확도가 두드러지게 개선되어, 제안된 생성 신호가 실제 진단 작업에 도움이 될 수 있음을 입증하였다. 다만, 생성한 리드를 2개 이상 결합하여 분류를 수행할 경우에는 성능 저하가 발생하는 문제도 관찰되었다.

이러한 성능 저하는 개별 리드 생성 과정에서 발생하는 노이즈가 누적되고, 리드 간의 생리학적 상관관계가 충분히 보존되지 못했기 때

문으로 해석된다. 따라서 향후 연구에서는 리드 간의 연결성을 반영할 수 있는 구조적 개선과 노이즈 누적 최소화를 위한 정교한 학습 전략을 통해 생성 신호의 일관성과 분류 성능을 개선할 예정이다.

References

- [1] Bae, C., Kim, J., Kim, S., et al. (2022). Electrocardiogram lead conversion from single-lead blindly-segmented signals.
- [2] Shome, D., et al. (2023). Region-Disentangled Diffusion Model for High-Fidelity PPG-to-ECG Translation.
- [3] Golany, T., & Radinsky, K. (2019). PGANs: Personalized Generative Adversarial Networks for ECG Synthesis.
- [4] Chen, Y., et al. (2022). ECG-Dual-GAN: Generative Adversarial Network Based Synthetic ECG Generation to Improve Deep ECG Classification. *IEEE Journal of Biomedical and Health Informatics*, 26(1), 12-21.
- [5] Alcaraz, R., & Strodthoff, N. (2023). Conditional ECG Generation from Clinical Statements Using Diffusion Models. *arXiv preprint*.
- [6] Neifar, N., et al. (2023). DiffECG: A Versatile Probabilistic Diffusion Model for ECG Signals Synthesis. *arXiv preprint*.
- [7] Ho, J., et al. (2020). Denoising Diffusion Probabilistic Models.
- [8] Dhariwal, P., & Nichol, A. (2021). Diffusion Models Beat GANs on Image Synthesis.
- [9] Oppenheim, A. V., & Schaffer, R. W. (2009). *Discrete-Time Signal Processing* (3rd ed.). Prentice Hall.
- [10] Sörnmo, L., & Laguna, P. (2005). *Bioelectrical Signal Processing in Cardiac and Neurological Applications*. Elsevier.
- [11] Clifford, G. D., Azuaje, F., & McSharry, P. E. (2006). *Advanced Methods and Tools for ECG Data Analysis*. Artech House.